

Libro de códigos — Establecimientos DIVERSIFICADO (MINEDUC)

Metadatos y diccionario de variables del conjunto de datos limpio `datos/clean/establecimientos_diversificado_limpio.csv`.

Metadatos globales

Campo	Valor
Fuente	Buscador de establecimientos del MINEDUC
URL	http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
Fecha de extracción	2026-07-12 (corrida registrada en <code>automatizacion/scrapper.log</code> , confirmada por el <code>mtime</code> de los CSV en <code>datos/crudos/</code>)
Versión	v1.0
Registros	11,867
Variables	31
Autores	Esteban, Ernesto, Hugo

Plantilla por columna

Cada variable se documenta con los siguientes campos:

- **Descripción:** qué representa la columna.
- **Tipo de dato:** tipo de dato con el que se almacena en el CSV limpio.
- **Dominio permitido:** qué valores son válidos.
- **Valores posibles:** cardinalidad / catálogo observado.
- **Tratamiento aplicado:** transformación de limpieza aplicada (ver `docs/transformaciones.md` para el detalle con conteos).
- **Variable derivada:** Sí/No — de dónde y cómo se calculó, si aplica.
- **Fecha de extracción:** fecha en que se obtuvo el dato de la fuente.
- **Fuente:** de dónde proviene el dato.
- **Versión:** versión de este libro de códigos bajo la cual se documentó la columna.

Columnas de Esteban

`establecimiento`

- **Descripción:** Nombre oficial del establecimiento educativo, tal como lo registra el MINEDUC.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena no vacía en MAYÚSCULAS; "NA" si no hay dato.
- **Valores posibles:** 6,668 valores únicos observados sobre 11,867 registros; es texto libre (nombre propio), no una categórica cerrada.

- **Tratamiento aplicado:** NFC + colapsar espacios múltiples + `strip()` + quitar caracteres de control + `.upper()` defensivo; 5 valores vacíos (IDs `114`, `1814`, `3644`, `7592`, `9627`) → "NA" ; comillas dobles y variantes con/sin tilde se conservan tal cual (no se autocorrigen, ver `docs/transformaciones.md#establecimiento`).
- **Variable derivada:** No — proviene directamente de la columna cruda `establecimiento`, solo normalizada en formato.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`establecimiento_raw`

- **Descripción:** Valor original de `establecimiento` tal como llegó de la fuente, sin ninguna normalización.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos, espacios múltiples y caracteres de control.
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (ver `datos/interim/diagnostico_unicos.csv`).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `establecimiento`.
- **Variable derivada:** Sí — copia literal de la columna `establecimiento` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_establecimiento.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`direccion`

- **Descripción:** Dirección física del establecimiento (calle, avenida, zona, colonia, etc.).
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena no vacía en MAYÚSCULAS con abreviaturas estandarizadas; "NA" si no hay dato.
- **Valores posibles:** 7,528 valores únicos observados; texto libre, no una categórica cerrada.
- **Tratamiento aplicado:** NFC + colapsar espacios múltiples + `strip()` + quitar caracteres de control + `.upper()` ; 89 vacíos/placeholders no informativos (`.`, `---`, `S/N`, etc.) → "NA" ; abreviaturas estandarizadas (`AV` → `AVENIDA`, `COL` → `COLONIA`, `Z.` → `ZONA`, `BO` → `BARRIO`, `# / No` → `NO.`). Ver `docs/transformaciones.md#direccion`.
- **Variable derivada:** No — proviene directamente de la columna cruda `direccion`, normalizada en formato y vocabulario.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`direccion_raw`

- **Descripción:** Valor original de `direccion` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos y placeholders no informativos.
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido.
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar.
- **Variable derivada:** Sí — copia literal de la columna `direccion` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_direccion.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`archivo_origen`

- **Descripción:** Nombre del archivo CSV crudo (uno por departamento) del que proviene cada fila.

- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Uno de los nombres de archivo `establecimientos_diversificado_<codigo>_<departamento>.csv` generados por `automatizacion/descarga.py`.
- **Valores posibles:** 23 valores únicos (uno por archivo/departamento descargado; Guatemala se descarga en 2 archivos — `00_ciudad_capital` y `01_guatemala` — antes de la fusión que hace Ernesto en `departamento`).
- **Tratamiento aplicado:** Ninguno adicional a la asignación hecha en la unión; ya es un nombre de archivo consistente, no requiere normalización.
- **Variable derivada:** Sí — asignada en `automatizacion/unir_datos.py` (`df["archivo_origen"] = archivo.name`) al concatenar los 23 CSV crudos de `datos/crudos/`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC (nombre de archivo generado por el propio pipeline de descarga).
- **Versión:** v1.0.

id_registro

- **Descripción:** Identificador único y estable de cada fila del conjunto de datos, para referenciarla en cualquier fase (limpieza, deduplicación, validación) sin depender del índice de pandas.
- **Tipo de dato:** Texto (string) — almacenado como texto por consistencia con el `dtype=str` de todo el pipeline, aunque semánticamente es un entero.
- **Dominio permitido:** Enteros positivos consecutivos.
- **Valores posibles:** 11,867 valores únicos, rango `1..11867`.
- **Tratamiento aplicado:** Ninguno posterior a su asignación; se excluye explícitamente (junto con `archivo_origen`) del chequeo de filas idénticas al buscar duplicados exactos.
- **Variable derivada:** Sí — entero incremental estable (1..N), asignado en `automatizacion/unir_datos.py` (`unido["id_registro"] = range(1, len(unido) + 1)`) después de ordenar y concatenar los 23 CSV crudos.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC (id generado por el propio pipeline de unión).
- **Versión:** v1.0.

Columnas de Ernesto

departamento

- **Descripción:** Departamento de Guatemala en el que se ubica el establecimiento educativo.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Uno de los 22 departamentos oficiales del INE, en MAYÚSCULAS con tildes correctas; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:`.
- **Valores posibles:** 22 categorías (catálogo oficial INE, ver `limpieza/catalogos.py`).
- **Tratamiento aplicado:** Fusión de `CIUDAD CAPITAL` (código 00) + `GUATEMALA` (código 01) → valor canónico `GUATEMALA` (2,161 registros fusionados), por ser un artefacto del selector de descarga y no una entidad administrativa distinta; normalización de tildes a la forma canónica del INE (2,025 registros, comparación sin tildes y valor guardado con tildes); `.upper()` defensivo; 0 valores fuera de catálogo. Ver `docs/transformaciones.md#departamento`.
- **Variable derivada:** No — proviene directamente de la columna cruda `departamento`, normalizada y fusionada; el original queda en `departamento_raw`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

departamento_raw

- **Descripción:** Valor original de `departamento` tal como llegó de la fuente, sin fusión ni normalización.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena; conserva `CIUDAD CAPITAL` y las variantes sin tildes (`PETEN` , `SOLOLA` , etc.).
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (incluye `CIUDAD CAPITAL` como valor separado de `GUATEMALA`).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `departamento` (permite auditar la fusión 00+01 y la normalización de tildes).
- **Variable derivada:** Sí — copia literal de la columna `departamento` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_departamento.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

municipio

- **Descripción:** Municipio en el que se ubica el establecimiento educativo.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Uno de los ~340 municipios oficiales del INE, válido **para su departamento**, en MAYÚSCULAS con tildes correctas; sin match suficiente se marca con prefijo `REVISAR:` .
- **Valores posibles:** ~340 municipios (catálogo oficial INE validado por departamento, ver `limpieza/catalogos.py`).
- **Tratamiento aplicado:** Validación contra el catálogo filtrado por el `departamento` ya limpio: 11,858 registros con match exacto (sin tildes), 1 typo corregido con RapidFuzz (`token_sort_ratio ≥ 90`), 8 sin match marcados `REVISAR:` y exportados a `datos/interim/municipios_fuera_catalogo.csv` ; valor canónico guardado con tildes y MAYÚSCULAS. Ver `docs/transformaciones.md#municipio` .
- **Variable derivada:** No — proviene directamente de la columna cruda `municipio` , normalizada y validada; el original queda en `municipio_raw` .
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

municipio_raw

- **Descripción:** Valor original de `municipio` tal como llegó de la fuente, sin normalizar ni corregir.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos typos y variantes sin tildes.
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (352 valores únicos observados).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar; hace auditable cada corrección de typo (RapidFuzz) y cada valor marcado `REVISAR:` .
- **Variable derivada:** Sí — copia literal de la columna `municipio` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_municipio.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

codigo

- **Descripción:** Código único del establecimiento educativo asignado por el MINEDUC.
- **Tipo de dato:** Texto (string) — se mantiene como texto siempre para conservar los ceros a la izquierda (convertirlo a `int` / `float` los perdería).
- **Dominio permitido:** Cadena que cumple el patrón `##-##-####-##` (`^\d{2}-\d{2}-\d{4}-\d{2}$`); cualquier valor fuera de patrón se marca con prefijo `REVISAR:` .
- **Valores posibles:** 11,867 valores únicos (uno por registro); 0 inválidos en el dataset actual.

- **Tratamiento aplicado:** `strip()` defensivo; verificación (`assert`) del patrón `##-##-####-##` sobre los 11,867 registros y de la unidad (`nunique() == len(df)`); 0 inválidos y 0 duplicados detectados. Ver `docs/transformaciones.md#codigo`.
- **Variable derivada:** No — proviene directamente de la columna cruda `codigo`; el original queda en `codigo_raw`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`codigo_raw`

- **Descripción:** Valor original de `codigo` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos posibles espacios al inicio/fin.
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (11,867 únicos).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `codigo`.
- **Variable derivada:** Sí — copia literal de la columna `codigo` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_codigo.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`distrito`

- **Descripción:** Distrito escolar del establecimiento educativo, según la organización interna del MINEDUC.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cadena con formato `##-###`; "NA" si no hay dato. No existe catálogo público oficial de distritos escolares, por lo que solo se valida el formato, no el contenido.
- **Valores posibles:** Texto libre bajo el patrón `##-###`; no es una categórica cerrada verificable.
- **Tratamiento aplicado:** `strip()` defensivo y normalización de formato; 532 valores vacíos → "NA". No se corrige el contenido por falta de catálogo de referencia. Ver `docs/transformaciones.md#distrito_departamental_nivel`.
- **Variable derivada:** No — proviene directamente de la columna cruda `distrito`; el original queda en `distrito_raw`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`distrito_raw`

- **Descripción:** Valor original de `distrito` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos y variantes de formato (`01-`, `01-403`, etc.).
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido.
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `distrito`.
- **Variable derivada:** Sí — copia literal de la columna `distrito` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_distrito_departamental_nivel.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`departamental`

- **Descripción:** Dirección Departamental de Educación (DIDEDUC) del MINEDUC a la que pertenece el establecimiento.
- **Tipo de dato:** Texto (string).

- **Dominio permitido:** Nombre de dirección departamental en MAYÚSCULAS con tildes correctas, consistente con el `departamento` limpio (o una de sus subdivisiones administrativas conocidas).
- **Valores posibles:** 26 valores únicos — 22 departamentos más Guatemala subdividida en 4 zonas administrativas del MINEDUC (`GUATEMALA NORTE` , `GUATEMALA SUR` , `GUATEMALA ORIENTE` , `GUATEMALA OCCIDENTE`). La subdivisión es **intencional**, no un error.
- **Tratamiento aplicado:** `strip()` + `NFC` + `.upper()` con tildes correctas; 0 cambios de caja detectados. Se documentan los 26 valores observados y su mapeo al departamento oficial. Ver `docs/transformaciones.md#distrito_departamental_nivel` .
- **Variable derivada:** No — proviene directamente de la columna cruda `departamental` ; el original queda en `departamental_raw` .
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`departamental_raw`

- **Descripción:** Valor original de `departamental` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidas posibles variantes de escritura.
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (26 valores únicos observados).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `departamental` .
- **Variable derivada:** Sí — copia literal de la columna `departamental` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_distrito_departamental_nivel.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`nivel`

- **Descripción:** Nivel escolar del establecimiento educativo.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Un único valor: `DIVERSIFICADO` (el dataset se filtró por este nivel en la descarga).
- **Valores posibles:** 1 categoría — `DIVERSIFICADO` .
- **Tratamiento aplicado:** Verificación (assert) de que `nivel.nunique() == 1` y `nivel == "DIVERSIFICADO"` en los 11,867 registros; 0 anomalías. No se modifica el valor. Ver `docs/transformaciones.md#distrito_departamental_nivel` .
- **Variable derivada:** No — proviene directamente de la columna cruda `nivel` ; el original queda en `nivel_raw` .
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

`nivel_raw`

- **Descripción:** Valor original de `nivel` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena (defensivo; en la práctica siempre `DIVERSIFICADO`).
- **Valores posibles:** Misma cardinalidad que la columna cruda en el CSV unido (1 valor único observado).
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `nivel` (defensivo por si una futura descarga incluyera otro nivel).
- **Variable derivada:** Sí — copia literal de la columna `nivel` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_distrito_departamental_nivel.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.

- **Versión:** v1.0.

Columnas de Hugo

telefono

- **Descripción:** Número de teléfono principal de contacto del establecimiento educativo.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cadena con formato `####-####` (8 dígitos, convención de Guatemala) o `"NA"` si no hay dato válido.
- **Valores posibles:** 10,794 números válidos formateados; texto libre bajo el patrón `####-####`, no una categórica cerrada.
- **Tratamiento aplicado:** NFC + quitar caracteres de control + `strip()`; se dejan solo dígitos y se aplica formato `####-####`; 946 vacíos → `"NA"`; 127 inválidos (con letras o con un número de dígitos distinto de 8) → `"NA"`; en celdas con varios números se conserva el primero aquí y el resto en `telefono_adicionales`. Ver `docs/transformaciones.md#telefono`.
- **Variable derivada:** No — proviene directamente de la columna cruda `telefono`, solo normalizada y validada; el original queda en `telefono_raw`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

telefono_adicionales

- **Descripción:** Teléfonos secundarios del establecimiento, cuando la celda original contenía varios números.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Uno o más números con formato `####-####` unidos por `;`, o `"NA"` si no hay números adicionales.
- **Valores posibles:** 119 registros con al menos un número adicional; el resto es `"NA"`.
- **Tratamiento aplicado:** Números de 8 dígitos extra de celdas con múltiples teléfonos (separados por `/`, `;`, `Y/E` o dígitos concatenados en múltiplos de 8), formateados `####-####` y unidos por `;` (`"NA"` si no hay). Ver `docs/transformaciones.md#telefono`.
- **Variable derivada:** Sí — extraída en `limpieza/limpiar_telefono.py` a partir de los números secundarios de `telefono_raw`, para preservar los teléfonos extra sin romper la atomicidad de `telefono`.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

telefono_raw

- **Descripción:** Valor original de `telefono` tal como llegó de la fuente, sin ninguna normalización.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos, letras, separadores y varios números en una misma celda.
- **Valores posibles:** Misma cardinalidad que la columna cruda `telefono` en el CSV unido.
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `telefono` y `telefono_adicionales`.
- **Variable derivada:** Sí — copia literal de la columna `telefono` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_telefono.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

supervisor

- **Descripción:** Nombre del supervisor educativo asignado al establecimiento.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Nombre propio en MAYÚSCULAS; "NA" si no hay dato.
- **Valores posibles:** Texto libre (nombre propio de persona), no una categórica cerrada.
- **Tratamiento aplicado:** Quitar caracteres invisibles/de control (Cc / Cf) + NFC + `strip()` + colapsar espacios múltiples + `.upper()` ; 535 vacíos → "NA" ; se normaliza formato, no ortografía. Ver `docs/transformaciones.md#personas` .
- **Variable derivada:** No — proviene directamente de la columna cruda `supervisor` , solo normalizada en formato; el original queda en `supervisor_raw` .
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

supervisor_raw

- **Descripción:** Valor original de `supervisor` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos, placeholders y caracteres invisibles.
- **Valores posibles:** Misma cardinalidad que la columna cruda `supervisor` en el CSV unido.
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `supervisor` .
- **Variable derivada:** Sí — copia literal de la columna `supervisor` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_personas.py`).
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

director

- **Descripción:** Nombre del director del establecimiento educativo.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Nombre propio en MAYÚSCULAS; "NA" si no hay dato.
- **Valores posibles:** Texto libre (nombre propio de persona), no una categórica cerrada.
- **Tratamiento aplicado:** Quitar caracteres invisibles/de control (Cc / Cf) + NFC + `strip()` + colapsar espacios múltiples + `.upper()` ; 2,143 → "NA" (1,733 vacíos + 410 placeholders no informativos como `-` , `.` , `SIN DATO` , `XXX`); se normaliza formato, no ortografía. Ver `docs/transformaciones.md#personas` .
- **Variable derivada:** No — proviene directamente de la columna cruda `director` , solo normalizada en formato; el original queda en `director_raw` .
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

director_raw

- **Descripción:** Valor original de `director` tal como llegó de la fuente.
- **Tipo de dato:** Texto (string).
- **Dominio permitido:** Cualquier cadena, incluidos vacíos, placeholders y caracteres invisibles.
- **Valores posibles:** Misma cardinalidad que la columna cruda `director` en el CSV unido.
- **Tratamiento aplicado:** Ninguno — se preserva sin modificar como respaldo/trazabilidad de `director` .
- **Variable derivada:** Sí — copia literal de la columna `director` del CSV unido, insertada antes de aplicar la limpieza (`limpieza/limpiar_personas.py`).
- **Fecha de extracción:** 2026-07-12.

- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

sector

- **Descripción:** Sector administrativo bajo el cual opera el establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category`.
- **Dominio permitido:** Uno de 4 valores canónicos: `COOPERATIVA`, `MUNICIPAL`, `OFICIAL`, `PRIVADO`; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:`.
- **Valores posibles:** 4 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()`, MAYÚSCULAS) + mapeo explícito a set canónico; fuera de catálogo → `REVISAR:`. Ver `docs/transformaciones.md#categoricas`.
- **Variable derivada:** No — proviene directamente de la columna cruda `sector`, solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

area

- **Descripción:** Área geográfica en la que se ubica el establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category`.
- **Dominio permitido:** Uno de 3 valores canónicos: `RURAL`, `URBANA`, `SIN ESPECIFICAR`; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:`.
- **Valores posibles:** 3 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()`, MAYÚSCULAS) + mapeo explícito a set canónico; fuera de catálogo → `REVISAR:`. Ver `docs/transformaciones.md#categoricas`.
- **Variable derivada:** No — proviene directamente de la columna cruda `area`, solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

status

- **Descripción:** Estado operativo del establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category`.
- **Dominio permitido:** Uno de 5 valores canónicos: `ABIERTA`, `CERRADA DEFINITIVAMENTE`, `CERRADA TEMPORALMENTE`, `TEMPORAL NOMBRAMIENTO`, `TEMPORAL TITULOS`; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:`.
- **Valores posibles:** 5 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()`, MAYÚSCULAS) + mapeo explícito a set canónico; fuera de catálogo → `REVISAR:`. Ver `docs/transformaciones.md#categoricas`.
- **Variable derivada:** No — proviene directamente de la columna cruda `status`, solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

modalidad

- **Descripción:** Modalidad lingüística de enseñanza del establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category`.

- **Dominio permitido:** Uno de 2 valores canónicos: `BILINGUE` , `MONOLINGUE` (sin diéresis, tal como la fuente); cualquier valor fuera de catálogo se marca con prefijo `REVISAR:` .
- **Valores posibles:** 2 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()` , MAYÚSCULAS) + mapeo explícito a set canónico (incluye `MONOLINGÜE` → `MONOLINGUE` , `BILINGÜE` → `BILINGUE`); fuera de catálogo → `REVISAR:` . Ver `docs/transformaciones.md#categoricas` .
- **Variable derivada:** No — proviene directamente de la columna cruda `modalidad` , solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

jornada

- **Descripción:** Jornada horaria en la que funciona el establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category` .
- **Dominio permitido:** Uno de 6 valores canónicos: `DOBLE` , `INTERMEDIA` , `MATUTINA` , `NOCTURNA` , `SIN JORNADA` , `VESPERTINA` ; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:` .
- **Valores posibles:** 6 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()` , MAYÚSCULAS) + mapeo explícito a set canónico (incluye `S/J` → `SIN JORNADA`); fuera de catálogo → `REVISAR:` . Ver `docs/transformaciones.md#categoricas` .
- **Variable derivada:** No — proviene directamente de la columna cruda `jornada` , solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.

plan

- **Descripción:** Plan o régimen de estudios del establecimiento educativo.
- **Tipo de dato:** Texto (string) en el CSV limpio; su tipo analítico natural es `category` .
- **Dominio permitido:** Uno de 13 valores canónicos: `A DISTANCIA` , `DIARIO(REGULAR)` , `DOMINICAL` , `FIN DE SEMANA` , `INTERCALADO` , `IRREGULAR` , `MIXTO` , `SABATINO` , `SEMIPRESENCIAL` , `SEMIPRESENCIAL (DOS DÍAS A LA SEMANA)` , `SEMIPRESENCIAL (FIN DE SEMANA)` , `SEMIPRESENCIAL (UN DÍA A LA SEMANA)` , `VIRTUAL A DISTANCIA` ; cualquier valor fuera de catálogo se marca con prefijo `REVISAR:` .
- **Valores posibles:** 13 categorías.
- **Tratamiento aplicado:** Normalización (NFC, quitar control chars, colapsar espacios, `strip()` , MAYÚSCULAS) + mapeo explícito a set canónico (incluye `DIARIO (REGULAR)` → `DIARIO(REGULAR)` , `REGULAR` → `DIARIO(REGULAR)`); fuera de catálogo → `REVISAR:` . Ver `docs/transformaciones.md#categoricas` .
- **Variable derivada:** No — proviene directamente de la columna cruda `plan` , solo normalizada y validada contra el catálogo.
- **Fecha de extracción:** 2026-07-12.
- **Fuente:** Buscador de establecimientos del MINEDUC.
- **Versión:** v1.0.